

# LLM2Seq

## Repurposing LLM Source Encoders for Encoder-Decoder Summarization with Self-Distilled MTP

Kiều Giang Biên

Hanoi University of Science and Technology

Báo cáo mini project

Tóm tắt trừu tượng tiếng Việt với token-level memory và verified MTP

## Từ bài toán đến hướng tiếp cận

### Bài toán

Tóm tắt trừu tượng cần đọc nguồn và viết lại ngắn gọn.

### Khoảng trống

Decoder-only LLM sinh tốt, nhưng khó dùng trực tiếp như encoder.

### Hướng làm

LLM đọc nguồn. Adapter nối sang decoder để sinh tóm tắt.

LLM2Seq giữ token-level memory thay vì nén nguồn quá sớm.

Decoder vẫn thấy chi tiết nguồn, trong khi mô hình tận dụng biểu diễn mạnh từ LLM.


# Vì sao không chỉ dùng nén ngữ cảnh?

## Nén ngữ cảnh


- Nén văn bản dài thành biểu diễn ẩn ngắn hơn.
- Hữu ích cho suy luận với ngữ cảnh dài.
- Không tối ưu riêng cho tóm tắt bám nguồn.

## LLM2Seq

- Giữ token-level memory cho từng token nguồn.
- Decoder đọc nguồn bằng cross-attention.
- Giảm nguy cơ mất thực thể, số liệu, bước thao tác.



# LLM2Seq: tổng quan kiến trúc




Source encoder từ LLM → adapter tạo memory → decoder nhẹ → verified MTP.

# Adapter: biến hidden states thành memory

## Ý tưởng

- Lấy hidden states từ source encoder.
- Kết hợp nhiều tầng ẩn để giữ cả thông tin nông và sâu.
- Gated residual projection đưa biểu diễn sang không gian decoder.
- Decoder đọc source memory bằng cross-attention.



Mục tiêu: tái sử dụng biểu diễn mạnh mà vẫn giữ ranh giới encoder-decoder.

Adapter là lớp nối quan trọng: không tạo encoder mới từ đầu, mà chuyển hidden states thành memory dùng được cho decoder.


# Self-distilled MTP: tăng tốc có kiểm chứng

## Huấn luyện

- Huấn luyện mô hình tóm tắt chính trước.
- Đóng băng encoder, adapter và decoder.
- Chỉ huấn luyện 4 MTP heads bằng CE + KL.

## Suy luận


- MTP heads dự đoán trước các token tương lai.
- Decoder chính kiểm chứng từng token nhập.
- Chỉ sinh ra token đã được kiểm chứng.



chỉ nhận token đã được kiểm chứng

# Dữ liệu: Vietnamese WikiLingua

Phân chia dữ liệu WikiLingua tiếng Việt



## Sau tiền xử lý

- Huấn luyện: 13,999
- Xác thực: 1,680
- Kiểm thử: 3,901
- Tổng sử dụng: 19,580

Một test record rỗng bị loại bỏ.


# Thiết lập thí nghiệm

| Hệ thống so sánh                                                                                                             | Thước đo                                                                                                                                | Huấn luyện                                                                                                                                 |
|------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------|
| <ul style="list-style-type: none"><li>• LLM2Seq-Llama</li><li>• LLM2Seq-Qwen</li><li>• T5Gemma làm mô hình so sánh</li></ul> | <ul style="list-style-type: none"><li>• ROUGE-1/2/L</li><li>• BERTScore</li><li>• Thống kê độ dài</li><li>• Token/s và độ trễ</li></ul> | <ul style="list-style-type: none"><li>• 3 giai đoạn</li><li>• LoRA để thích nghi encoder</li><li>• MTP heads huấn luyện sau cùng</li></ul> |

Câu hỏi chính: chất lượng tóm tắt, kiểm soát độ dài và tốc độ suy luận thực tế.  
Tốc độ chỉ được so sánh khi cùng mô hình và cùng thiết lập batch.




# Kết quả chính: chất lượng tóm tắt



LLM2Seq-Qwen: đạt R-1 54.01 và BERT-F1 73.42.


T5Gemma: tốt hơn ở R-2/R-L, nhưng sinh dài hơn đáng kể.

# Kết quả độ dài: không chỉ nhìn ROUGE



**Cách đọc:** Llama quá ngắn, Qwen gần độ dài tham chiếu hơn, còn T5Gemma đầy đủ hơn nhưng thường sinh dài.

# MTP: nhiều token mỗi bước, tăng tốc vừa phải




## Quan sát trên Qwen

- AR: 95.87 tok/s
- MTP: 111.71 tok/s
- Tăng tốc: 1.17x
- Sinh: 2.30 token/bước

Số token được sinh mỗi bước không đồng nghĩa trực tiếp với thời gian chạy thực tế.

# Độ trễ MTP bị nghẽn ở đâu?



## Cách đọc

Nếu MTP chỉ giảm thời gian nhờ sinh 2.30 token/bước, độ trễ kỳ vọng là 0.339s. Thực tế đo được là 0.662s.

## Ý nghĩa

Phần chênh 0.323s cho thấy tốc độ bị giữ lại bởi kiểm chứng token, quản lý cache, điều phối tensor và chi phí Python.

# Demo hệ thống

LLM2Seq

Text Summarization

Model: Ready

Embed-Embedding-0.48

Source Text

WikiLingua Text Sample

X Clear

Dùng để chứa nội dung văn bản gốc để xử lý hoặc gán là mẫu, vì những nội dung không khi quá nhỏ và ngắn. Từ tương hoặc tổng hợp là những vị trí trong nhà thích hợp cho cây này. Đây là nhiệt độ trong khoảng 24 - 29 độ C cho cây phát triển tốt. Dùng bình xịt để giữ ẩm cho hạt. Đảm bảo đất phải ẩm nhưng không ướt sũng hoặc khô quá. Tránh để đất bị úng nước, vì điều này có thể dẫn đến các vấn đề liên quan đến tình trạng tưới quá nhiều. Tưới cây theo lịch để giữ độ ẩm cho cây. Bạn có thể xịt nước cho cây một lần vào buổi sáng và một lần vào ban đêm để cung cấp đủ nước cho cây. Hạt cây sẽ cần ánh sáng 24 tiếng mỗi ngày, 7 ngày một tuần để phát triển. Bạn cần dùng ánh sáng trắng lạnh có nhiệt độ ổn định 22 độ C. Để đảm bảo cây 5 cm. Dùng đèn công suất 3 - 6W cho mỗi chậu. Đèn trồng cây ở Việt Nam giá khoảng vài chục đến vài trăm.

1,125 characters - 265 words

Decode Mode

Autoregressive

MTP Verified

Max Tokens: 256

Standard token-by-token decoding

Summarize

Summary

Autoregressive

Chọn vị trí có ánh sáng mạnh. Đặt cây con sang khu vực có nắng. Tỉm một chậu trồng cây lớn. Tưới cây khi đất khô hạt giống hoặc cây con vào chậu. Hạt giống sẽ vào chậu hoặc chậu cây con trong phòng ẩm áp và có ánh nắng.

Performance Metrics

LATENCY: 3.27s

TOKENS: 74

SPEED: 22.6 tok/s

LLM2Seq - Encoder-Decoder with Multi-Token Prediction © Github

## Chế độ autoregressive

LLM2Seq

Text Summarization

Model: Ready

Embed-Embedding-0.48

Source Text

WikiLingua Text Sample

X Clear

Dùng để chứa nội dung văn bản gốc để xử lý hoặc gán là mẫu, vì những nội dung không khi quá nhỏ và ngắn. Từ tương hoặc tổng hợp là những vị trí trong nhà thích hợp cho cây này. Đây là nhiệt độ trong khoảng 24 - 29 độ C cho cây phát triển tốt. Dùng bình xịt để giữ ẩm cho hạt. Đảm bảo đất phải ẩm nhưng không ướt sũng hoặc khô quá. Tránh để đất bị úng nước, vì điều này có thể dẫn đến các vấn đề liên quan đến tình trạng tưới quá nhiều. Tưới cây theo lịch để giữ độ ẩm cho cây. Bạn có thể xịt nước cho cây một lần vào buổi sáng và một lần vào ban đêm để cung cấp đủ nước cho cây. Hạt cây sẽ cần ánh sáng 24 tiếng mỗi ngày, 7 ngày một tuần để phát triển. Bạn cần dùng ánh sáng trắng lạnh có nhiệt độ ổn định 22 độ C. Để đảm bảo cây 5 cm. Dùng đèn công suất 3 - 6W cho mỗi chậu. Đèn trồng cây ở Việt Nam giá khoảng vài chục đến vài trăm.

1,125 characters - 265 words

Decode Mode

Autoregressive

MTP Verified

Max Tokens: 256

Multi-Token Prediction with train-head verification

Summarize

Summary

MTP Verified

Chọn vị trí có ánh sáng mạnh. Đặt cây con ở nơi có ánh nắng trực tiếp trên mặt trời. Đảm bảo cây nhận được nhiều ánh nắng mặt trời vào chậu hạt trong phòng ẩm áp và có ánh nắng. Tưới nước cho cây con. Tia cây.

Performance Metrics

LATENCY: 2.21s

TOKENS: 69

SPEED: 31.3 tok/s

ACCEPTANCE: 15.7%

STEPS: 27

SPEEDUP: 2.63x

LLM2Seq - Encoder-Decoder with Multi-Token Prediction © Github

## Chế độ verified MTP

# LLM2Seq cho thấy điều gì?

## Điểm làm được

- Source encoder từ LLM có thể tạo memory cho decoder.
- Token-level memory hữu ích cho tóm tắt bám nguồn.
- Verified MTP tạo ra tăng tốc thực, dù chưa lớn.

## Hạn chế hiện tại

- Chưa có ablation đầy đủ.
- Chưa có đánh giá factuality bằng con người.
- Chi phí triển khai MTP còn cao.

Kết quả chính là chứng minh tính khả thi, không phải khẳng định vượt trội tuyệt đối.  
Báo cáo không khẳng định thắng toàn diện T5Gemma hay các mô hình encoder-decoder chuyên biệt.

# Kết luận chính

| Kiến trúc                                 | Chất lượng                      | Tốc độ                    |
|-------------------------------------------|---------------------------------|---------------------------|
| LLM đọc nguồn<br>adapter nối sang decoder | Qwen gần R-1<br>tóm tắt gọn hơn | verified MTP<br>đạt 1.17x |

- LLM2Seq dùng source encoder từ LLM để tạo source memory cho decoder.
- Token-level memory giúp decoder vẫn thấy chi tiết trong văn bản nguồn.
- Verified MTP tăng tốc được, nhưng chi phí kiểm chứng và cache làm mức tăng tốc còn giới hạn.

Thông điệp chính: kiến trúc khả thi; ablation và đánh giá factuality là bước tiếp theo.



[github.com/BienKieu1411/LLM2Seq](https://github.com/BienKieu1411/LLM2Seq)