

LLM2Seq: Repurposing LLM Encoders for Encoder-Decoder Summarization with Self-Distilled Multi-Token Prediction

Kiều Giang Biên

Hanoi University of Science and Technology

Mentor: Đoàn Xuân Dũng - Viettel AI

Bài toán tóm tắt văn bản

Một văn bản nguồn dài x được rút thành tóm tắt ngắn y nhưng vẫn giữ các ý chính.

Trích xuất

Chọn câu hoặc đoạn đã xuất hiện trong nguồn.
Ít thay đổi cách diễn đạt.

Trừu tượng

Tổng hợp ý và diễn đạt lại bằng token mới.
Bài toán LLM2Seq.

Lai

Kết hợp sao chép chi tiết quan trọng và sinh cách diễn đạt mới.
Hữu ích khi cần độ trung thực cao.

Trong đề tài này, LLM2Seq tóm tắt từng văn bản tiếng Việt theo hướng trừu tượng.

Theo số nguồn, tóm tắt còn có thể là một văn bản hoặc đa văn bản; WikiLingua và LR-Sum thuộc thiết lập một văn bản.

Từ bài toán đến hướng tiếp cận

Bài toán

Tóm tắt trừu tượng cần hiểu toàn bộ nguồn, nhưng vẫn sinh đầu ra ngắn và bám nội dung.

Khoảng trống

Decoder-only LLM xử lý nguồn và đầu ra trong cùng causal stream, không có source memory riêng cho cross-attention.

Hướng tiếp cận

Dùng LLM làm source encoder; adapter biến hidden states thành cross-attention memory cho decoder nhẹ.

Mục tiêu: giữ chi tiết theo từng token trong nguồn, đồng thời giảm chi phí sinh.

Vì sao giữ token-level memory thay vì nén nguồn sớm?

Nén ngữ cảnh

- Nén nguồn thành số lượng latent token nhỏ hơn.
- Phù hợp với suy luận ngữ cảnh dài.
- Có nguy cơ làm mất chi tiết cục bộ.

LLM2Seq

- Giữ source memory theo từng token.
- Decoder truy cập trực tiếp bằng cross-attention.
- Hạn chế mất tên riêng, số liệu và trình tự thao tác.

Token-level memory giúp decoder tiếp tục truy cập chi tiết trong nguồn.

So sánh về mặt khái niệm, không phải một empirical baseline.

Đóng góp chính

1. Model architecture

Xây dựng encoder-decoder summarizer dùng LLM-based source encoder và lightweight decoder.

2. Memory adapter

Thiết kế source-memory bridge: layer fusion, gated residual projection, salience gate, EncStack và global memory tokens.

3. Efficient decoding


Tích hợp self-distilled MTP như speed module hậu huấn luyện và xây dựng verified decoding.

4. Evaluation and system

Huấn luyện trên hai bộ dữ liệu tiếng Việt, đánh giá chất lượng-độ dài-tốc độ và xây dựng web demo.

Điểm mới cốt lõi: source-memory bridge kết hợp biểu diễn đa tầng, gated projection, token salience và global memory để nối LLM encoder với decoder nhẹ.


LLM2Seq: tổng quan kiến trúc



Memory Adapter: từ LLM hidden states đến decoder memory

Kiến trúc chi tiết adapter

1. **Token-wise Layer Fusion:** mỗi token có thể cần thông tin từ độ sâu LLM khác nhau.
2. **Gated Residual Projection:** chiếu sang decoder space qua residual path để hạn chế mất thông tin nguồn.
3. **Token Saliency Gate:** nhấn mạnh token quan trọng mà không loại token khác.
4. **EncStack:** cho source token đã thích nghi tương tác và tinh chỉnh lẫn nhau.
5. **Global Memory Tokens:** cung cấp document-level workspace cho decoder.



Huấn luyện ba giai đoạn

Mục tiêu: ổn định việc học tóm tắt trước, sau đó mới tối ưu tốc độ.

GD 1: Học kết nối

Freeze

LLM encoder

Train

Adapter và decoder

Mục tiêu

Decoder học đọc bộ nhớ nguồn M .



GD 2: Thích nghi

Thêm

LoRA trên LLM encoder

Train

LoRA, adapter và decoder

Mục tiêu

Encoder thích nghi cho tóm tắt tiếng Việt.



GD 3: Tăng tốc

Freeze

Mô hình sau GD 2

Train

4 MTP heads

Mục tiêu

Tăng tốc hậu huấn luyện; giữ nguyên mục tiêu tóm tắt.

Self-distilled MTP và verified decoding

Huấn luyện: self-distilled MTP

- **Teacher:** frozen main decoder head.
- **Students:** four cascaded MTP heads.
- **Objective:** gold future-token CE + KL distillation.

Suy luận: verified decoding

- Prefix → draft future tokens.
- Main decoder verifies, nhận prefix khớp dài nhất.
- Correction token, rồi tiếp tục sinh.



Main decoder luôn giữ quyền quyết định token đầu ra.

Thiết lập thí nghiệm

Dữ liệu và mô hình

LLM2Seq-Llama	LLM2Vec-Sheared-LLaMA encoder
LLM2Seq-Qwen	Qwen3-Embedding-0.6B encoder
T5Gemma	T5Gemma-2-1B-1B LoRA baseline

Hai bộ dữ liệu tiếng Việt

- WikiLingua: 19.580 mẫu · hướng dẫn.
- LR-Sum: 14.595 mẫu · tin tức.

Đánh giá và câu hỏi nghiên cứu

- ROUGE-1/2/L, BERTScore, độ dài, token/s, latency.
- RQ1: Encoder LLM tạo source memory hữu ích?
- RQ2: Encoder ảnh hưởng chất lượng, độ dài, tốc độ?
- RQ3: Verified MTP tăng throughput thực?

Kiến trúc của hai source encoder

LLM2Vec-Sheared-LLaMA-mntp

Backbone: Sheared-LLaMA decoder-only.

Kiến trúc dùng: LLM2Vec encoder hai chiều (bidirectional attention + MNTP).

Qwen3-Embedding-0.6B


Backbone: Qwen3-0.6B-Base.

Kiến trúc dùng: Qwen3 causal Transformer đã huấn luyện cho text embedding đa ngôn ngữ.


So sánh hai cấu hình LLM2Seq và T5Gemma

Chất lượng tóm tắt theo dataset và metric

WikiLingua



Llama Qwen T5Gemma
LR-Sum





LLM2Seq-Qwen
> LLM2Seq-Llama
trên cả hai bộ dữ liệu
System-level comparison

54.01 $\approx$ 54.24
WikiLingua R-1

T5Gemma dẫn đầu
ở R-2 và R-L

Độ dài đầu ra so với tham chiếu



LLM2Seq-Llama: LLM2Vec-Sheared-LLaMA encoder • LLM2Seq-Qwen: Qwen3-Embedding-0.6B encoder

LLM2Seq-Llama
Sinh quá ngắn
(under-generation)

LLM2Seq-Qwen
Gần độ dài tham chiếu

T5Gemma
Sinh dài nhất

Ví dụ định tính: phủ nhiều ý hơn chưa đồng nghĩa với đúng nội dung

Văn bản nguồn (WikiLingua)

... cần nhắc giữa *chườm ấm* với *chườm lạnh*. Chườm ấm giúp làm khô mụn; chườm lạnh giúp giảm sưng đau. *Không nên chườm đá trong giai đoạn đầu.* ...

LLM2Seq-Llama

Sinh ra

Dùng gel lô hội.
Thoa sữa rửa mặt nhẹ dịu.
Dùng bằng dầu tràm trà.
Dưỡng ẩm cho da.

Nhận xét

Quá ngắn, bỏ thao tác chính và thêm nội dung ngoài nguồn.

LLM2Seq-Qwen

Sinh ra

Chườm đá viên lên mụn.
Chườm gạc ấm lên mụn để giảm đau.
Sử dụng tinh dầu tràm trà...

Nhận xét

Phủ nhiều ý hơn, nhưng mâu thuẫn với nguồn và diễn đạt chưa tự nhiên.

T5Gemma

Sinh ra

Chườm ấm hoặc chườm lạnh.
Thử dùng táo và mật ong...
Dùng tinh dầu tràm trà...

Nhận xét

Bao phủ nhiều chi tiết hơn và diễn đạt trôi chảy, nhưng đầu ra dài hơn.

MTP: giảm số bước, speedup bị giới hạn bởi verification

2.30


emitted tokens/step

1.17×

actual speedup

0.779 →
0.662 s

mean latency



Nhiều token mỗi bước không đồng nghĩa với speedup tương ứng.

Residual overhead được suy ra từ evaluation logs, không phải kernel-level profiling.

Demo hệ thống

LLM2Seq

Text Summarization

Model: Ready

Queue: tokenizing - 0.48

Source Text

WikiLingua Text Sample

X Clear

Bình dặt chậu gieo hạt trên bề mặt của sỏi hoặc gần lò sưởi, vì những nơi này không khí quá khô và nóng. Tủ tường hoặc tầng hầm là những vị trí trong nhà thích hợp cho cây này miễn. Duy trì nhiệt độ trong khoảng 24 - 28 độ C cho cây phát triển tốt. Dùng bình xịt để giữ ẩm cho hạt. Đảm bảo đất phải ẩm nhưng không ướt sũng hoặc nhỏ giọt. Tránh để đất bị úng nước, vì điều này có thể dẫn đến các vấn đề liên quan đến tình trạng tưới quá nhiều. Tưới cây theo lịch để giữ độ ẩm cho cây. Bạn có thể xịt nước cho cây một lần vào buổi sáng và một lần vào ban đêm để cung cấp đủ nước cho cây. Hạt cây gai dầu cần ánh sáng 24 tiếng mỗi ngày, 7 ngày một tuần để phát triển. Bạn cần dùng ánh sáng trắng lạnh có nhiệt độ ổn định 22 độ C. Để đến cách chậu cây 5 cm. Dùng đèn công suất 3 - 5W cho mỗi chậu. Đèn trồng cây ở Việt Nam giá khoảng vài chục đến vài trăm nghìn đồng. Bạn không biết cách chọn và lắp đèn thì mua đèn trồng cây cho người mới bắt đầu trồng cây để họ học hỏi.

1125 characters - 203 words

Decode Mode

Autoregressive

MTP Verified

Max Tokens: 256

Standard token-by-token decoding

Summarize

Summary

Autoregressive

Chọn vị trí có ánh sáng mạnh. Đặt cây con sang khu vực có nắng. Tìm một chậu trồng cây lớn. Tưới cây khi đất khô hạn giống hoặc cây con vào chậu. Hạt giống rễ vào chậu hoặc chậu cây con cây con trong phòng ẩm áp và có ánh nắng.

Performance Metrics

LATENCY

2.21s

TOKENS

74

SPEED

22.4 tok/s

LLM2Seq - Encoder-Decoder with Multi-Token Prediction. [GitHub](#)

Autoregressive

LLM2Seq

Text Summarization

Model: Ready

Queue: tokenizing - 0.48

Source Text

WikiLingua Text Sample

X Clear

Bình dặt chậu gieo hạt trên bề mặt của sỏi hoặc gần lò sưởi, vì những nơi này không khí quá khô và nóng. Tủ tường hoặc tầng hầm là những vị trí trong nhà thích hợp cho cây này miễn. Duy trì nhiệt độ trong khoảng 24 - 28 độ C cho cây phát triển tốt. Dùng bình xịt để giữ ẩm cho hạt. Đảm bảo đất phải ẩm nhưng không ướt sũng hoặc nhỏ giọt. Tránh để đất bị úng nước, vì điều này có thể dẫn đến các vấn đề liên quan đến tình trạng tưới quá nhiều. Tưới cây theo lịch để giữ độ ẩm cho cây. Bạn có thể xịt nước cho cây một lần vào buổi sáng và một lần vào ban đêm để cung cấp đủ nước cho cây. Hạt cây gai dầu cần ánh sáng 24 tiếng mỗi ngày, 7 ngày một tuần để phát triển. Bạn cần dùng ánh sáng trắng lạnh có nhiệt độ ổn định 22 độ C. Để đến cách chậu cây 5 cm. Dùng đèn công suất 3 - 5W cho mỗi chậu. Đèn trồng cây ở Việt Nam giá khoảng vài chục đến vài trăm nghìn đồng. Bạn không biết cách chọn và lắp đèn thì mua đèn trồng cây cho người mới bắt đầu trồng cây để họ học hỏi.

1125 characters - 203 words

Decode Mode

Autoregressive

MTP Verified

Max Tokens: 256

Multi-Token Prediction with main-head verification

Summarize

Summary

MTP Verified

Chọn vị trí có ánh sáng mạnh. Đặt cây con ở nơi có ánh nắng trực tiếp trên mặt trời. Đảm bảo cây nhận được nhiều ánh nắng mặt trời vào chậu hạt trong phòng ẩm áp và có ánh nắng. Tưới nước cho cây con. Tia cây.

Performance Metrics

LATENCY

2.21s

TOKENS

49

SPEED

31.3 tok/s

ACCEPTANCE

15.7%

STEPS

27

SPEEDUP

2.65x

LLM2Seq - Encoder-Decoder with Multi-Token Prediction. [GitHub](#)

Verified MTP

Thảo luận và hạn chế

Điểm đã đạt được

- LLM-based encoder cung cấp source memory hữu ích.
- Qwen tốt hơn Llama về chất lượng và kiểm soát độ dài.
- Verified MTP tạo speedup thực, không chỉ giảm số bước.

Vấn đề còn lại

- Chưa vượt T5Gemma ở ROUGE-2 và ROUGE-L.
- Chưa có full adapter ablation hay human factuality evaluation.
- MTP prototype còn chịu chi phí verification và cache.

Cấu hình Qwen cho chất lượng tốt hơn nhưng giải mã chậm hơn; khác biệt đến từ cả encoder, tokenizer, vocabulary và representation space.

Kết luận

Kiến trúc

LLM2Seq chuyển token-level LLM hidden states thành decoder-readable memory qua gated residual adapter.

Chất lượng

Qwen cải thiện rõ so với Llama và gần T5Gemma ở WikiLingua ROUGE-1, nhưng baseline vẫn mạnh hơn tổng thể.

Hiệu quả suy luận

Verified MTP đạt $1.17\times$ throughput; tốc độ thực phụ thuộc mạnh vào verification overhead.

Tiếp theo: adapter ablation · factuality evaluation · optimized verifier



Thank you
Questions?

github.com/BienKieu1411/LLM2Seq



Backup: phát biểu bài toán

Mục tiêu

Tìm mô hình ước lượng phân phối của bản tóm tắt $y = (y_1, \dots, y_n)$ dựa trên văn bản nguồn $x = (x_1, \dots, x_m)$:

$$p(y|x) = \prod_{t=1}^n p(y_t | y_{<t}, x)$$

Công thức hóa LLM2Seq

- **Encoder:** $H = E_{\theta}(x)$; **Adapter:** $M = A_{\phi}(H)$.
- **Decoder:** $p(y|x) = \prod_{t=1}^n p_{\psi}(y_t | y_{<t}, M)$.

Backup: bảng kết quả đầy đủ

Dataset	Model	R-1	R-2	R-L	BERT-F1
WikiLingua	LLM2Seq-Llama	48.36	15.54	29.05	73.02
	LLM2Seq-Qwen	54.01	20.83	31.83	73.42
	T5Gemma	54.24	27.42	33.89	74.98
LR-Sum	LLM2Seq-Llama	50.49	12.08	29.41	69.98
	LLM2Seq-Qwen	51.59	15.58	31.21	71.62
	T5Gemma	58.79	27.34	39.86	74.65

Blue: best LLM2Seq. Green: best overall.

Cấu hình mô hình

Memory adapter

- Selected layers: $[-1, -4, -8, -12]$
- 16 global memory tokens
- 4-layer EncStack
- Hidden size: 1024

Decoder and MTP

- 8-layer decoder
- 4 MTP heads
- Verified draft-and-verify inference
- LoRA adapts the encoder in Phase 2

Backup: khi nào MTP thực sự nhanh hơn?

Chi phí gần đúng

$$C_{AR} \approx nC_{AR-step} \quad C_{MTP} \approx \frac{n}{\bar{e}}(C_{AR-step} + C_{ver})$$

$$\bar{e} > 1 + \frac{C_{ver}}{C_{AR-step}}$$

Số token chấp nhận trung bình phải đủ lớn để bù chi phí verification.

Thông tin huấn luyện

Phase	Trainable modules	Mục tiêu
1	Adapter + decoder	Học kết nối source memory-decoder
2	LoRA + adapter + decoder	Thích nghi encoder cho summarization tiếng Việt
3	4 MTP heads	Self-distillation; không thay đổi mục tiêu tóm tắt chính

Failure case thứ hai: biểu lộ cảm xúc

Nguồn: bài hướng dẫn về khóc và cảm xúc

... những người được dạy kiềm chế và giấu kín cảm xúc từ bé thường khó biểu lộ cảm xúc khi lớn lên. Khóc là một phần thiết yếu của cuộc sống và có thể biểu hiện buồn, đau đớn, sợ hãi, hạnh phúc hoặc niềm vui.

LLM2Seq-Qwen

Hãy để bản thân bị trầm cảm. Hãy cười ra khỏi vùng an toàn của bạn. Hãy vui vẻ và đau khổ.

Hàm ý

Mô hình giữ được chủ đề chung nhưng sinh các chỉ dẫn sai hoặc không tự nhiên. ROUGE/BERTScore không phản ánh đầy đủ lỗi này.

Cần human factuality evaluation và phân loại lỗi, không chỉ tối ưu metric tự động.