

# LLM2Seq

## Repurposing LLM Source Encoders for Encoder-Decoder Summarization with Self-Distilled MTP

Kiều Giang Biên

Hanoi University of Science and Technology

Báo cáo mini project

Tóm tắt sinh tiếng Việt với token-level memory và verified MTP

## Từ bài toán đến hướng tiếp cận

### Bài toán

Tóm tắt trừu tượng cần đọc nguồn và viết lại ngắn gọn.

### Khoảng trống

Decoder-only LLM sinh tốt, nhưng khó dùng trực tiếp như encoder.

### Hướng làm

LLM source encoder đọc nguồn. Adapter nối sang decoder.

LLM2Seq giữ token-level memory thay vì nén nguồn quá sớm.

Decoder vẫn thấy chi tiết nguồn, trong khi mô hình tận dụng biểu diễn mạnh từ LLM.


# Vì sao không chỉ dùng nén ngữ cảnh?

## Nén ngữ cảnh


- Nén văn bản dài thành biểu diễn ẩn ngắn hơn.
- Hữu ích cho suy luận với ngữ cảnh dài.
- Không tối ưu riêng cho tóm tắt bám nguồn.

## LLM2Seq

- Giữ token-level memory cho từng token nguồn.
- Decoder đọc nguồn bằng cross-attention.
- Giảm nguy cơ mất thực thể, số liệu, bước thao tác.



# LLM2Seq: tổng quan kiến trúc




Source encoder từ LLM → adapter tạo memory → decoder nhẹ → verified MTP.

# Adapter: biến hidden states thành memory

## Ý tưởng

- Lấy hidden states từ source encoder.
- Kết hợp nhiều tầng ẩn để giữ cả thông tin nông và sâu.
- Gated residual projection đưa biểu diễn sang không gian decoder.
- Decoder đọc source memory bằng cross-attention.



Mục tiêu: tái sử dụng biểu diễn mạnh mà vẫn giữ ranh giới encoder-decoder.

Adapter là lớp nối quan trọng: không tạo encoder mới từ đầu, mà chuyển hidden states thành memory dùng được cho decoder.


# Self-distilled MTP: tăng tốc có kiểm chứng

## Huấn luyện

- Huấn luyện mô hình tóm tắt chính trước.
- Đóng băng encoder, adapter và decoder.
- Chỉ huấn luyện 4 MTP heads bằng CE + KL.

## Suy luận


- MTP heads dự đoán trước các token tương lai.
- Decoder chính kiểm chứng từng token nhập.
- Chỉ sinh ra token đã được kiểm chứng.



chỉ nhận token đã được kiểm chứng

# Dữ liệu: Vietnamese WikiLingua

Phân chia dữ liệu WikiLingua tiếng Việt



## Sau tiền xử lý

- Huấn luyện: 13,999
- Xác thực: 1,680
- Kiểm thử: 3,901
- Tổng sử dụng: 19,580

Một test record rỗng bị loại bỏ.

# Thiết lập thí nghiệm

## Hệ thống so sánh

- LLM2Seq-Llama
- LLM2Seq-Qwen
- T5Gemma làm mô hình so sánh

## Thước đo

- ROUGE-1/2/L
- BERTScore
- Thống kê độ dài
- Token/s và độ trễ


## Huấn luyện

- 3 giai đoạn
- LoRA để thích nghi encoder
- MTP heads huấn luyện sau cùng

Câu hỏi chính: chất lượng tóm tắt, kiểm soát độ dài và tốc độ suy luận thực tế.  
Llama-Qwen được so sánh khi cùng batch. AR-MTP được so sánh trong cùng model và cùng batch.




# Kết quả chính: chất lượng tóm tắt



LLM2Seq-Qwen: đạt R-1 54.01 và BERT-F1 73.42.


T5Gemma: cao hơn ở R-2, R-L và BERT-F1, nhưng sinh dài hơn đáng kể.

# Kết quả độ dài: không chỉ nhìn ROUGE



**Cách đọc:** Llama quá ngắn. Qwen gần độ dài tham chiếu hơn. T5Gemma đầy đủ hơn, nhưng thường sinh dài.

# MTP: nhiều token mỗi bước, tăng tốc vừa phải




## Quan sát trên Qwen

- AR: 95.87 tok/s
- MTP: 111.71 tok/s
- Tăng tốc: 1.17x
- Sinh ra: 2.30 token/bước
- Draft được nhận: 0.44 token/bước

Số token được sinh mỗi bước không đồng nghĩa trực tiếp với thời gian chạy thực tế.

# Độ trễ MTP bị nghẽn ở đâu?



## Cách đọc

Nếu MTP chỉ giảm thời gian nhờ sinh 2.30 token/bước, độ trễ kỳ vọng là 0.339s. Thực tế đo được là 0.662s.

## Ý nghĩa

Phần chênh 0.323s cho thấy tốc độ bị giữ lại bởi kiểm chứng token, quản lý cache, điều phối tensor và chi phí Python.

# Demo hệ thống

LLM2Seq

Text Summarization

Model: Ready

Embed-Embedding-0.48

Source Text

WikiLingua Test Sample

X Clear

Dùng để chứa nội dung văn bản gốc để xử lý hoặc gán là mẫu, vì những nội dung không khi quá nhỏ và ngắn. Từ tương hoặc tổng hợp là những vị trí trong nhà thích hợp cho cây này. Đây là nhiệt độ trong khoảng 24 - 29 độ C cho cây phát triển tốt. Dùng bình xịt để giữ ẩm cho hạt. Đảm bảo đất phải ẩm nhưng không ướt sũng hoặc khô quá. Tránh để đất bị úng nước, vì điều này có thể dẫn đến các vấn đề liên quan đến tình trạng tưới quá nhiều. Tưới cây theo lịch để giữ độ ẩm cho cây. Bạn có thể xịt nước cho cây một lần vào buổi sáng và một lần vào ban đêm để cung cấp đủ nước cho cây. Hạt cây sẽ cần ánh sáng 24 tiếng mỗi ngày, 7 ngày một tuần để phát triển. Bạn cần dùng ánh sáng trắng lạnh có nhiệt độ ổn định 22 độ C. Để đảm bảo cây 5 cm. Dùng đèn công suất 3 - 6W cho mỗi chậu. Đèn trồng cây ở Việt Nam giá khoảng vài chục đến vài trăm nghìn đồng.

1,123 characters - 265 words

Decode Mode

Autoregressive

MTP Verified

Max Tokens: 256

Standard token-by-token decoding

Summarize

Summary

Autoregressive

Chọn vị trí có ánh sáng mạnh. Đặt cây con sang khu vực có nắng. Tỉm một chậu trồng cây lớn. Tưới cây khi đất khô hạt giống hoặc cây con vào chậu. Hạt giống sẽ vào chậu hoặc chậu cây con trong phòng ẩm áp và có ánh nắng.

Performance Metrics

|         |        |            |
|---------|--------|------------|
| LATENCY | TOKENS | SPEED      |
| 3.27s   | 74     | 22.6 tok/s |

LLM2Seq - Encoder-Decoder with Multi-Token Prediction © Github

## Chế độ autoregressive

LLM2Seq

Text Summarization

Model: Ready

Embed-Embedding-0.48

Source Text

WikiLingua Test Sample

X Clear

Dùng để chứa nội dung văn bản gốc để xử lý hoặc gán là mẫu, vì những nội dung không khi quá nhỏ và ngắn. Từ tương hoặc tổng hợp là những vị trí trong nhà thích hợp cho cây này. Đây là nhiệt độ trong khoảng 24 - 29 độ C cho cây phát triển tốt. Dùng bình xịt để giữ ẩm cho hạt. Đảm bảo đất phải ẩm nhưng không ướt sũng hoặc khô quá. Tránh để đất bị úng nước, vì điều này có thể dẫn đến các vấn đề liên quan đến tình trạng tưới quá nhiều. Tưới cây theo lịch để giữ độ ẩm cho cây. Bạn có thể xịt nước cho cây một lần vào buổi sáng và một lần vào ban đêm để cung cấp đủ nước cho cây. Hạt cây sẽ cần ánh sáng 24 tiếng mỗi ngày, 7 ngày một tuần để phát triển. Bạn cần dùng ánh sáng trắng lạnh có nhiệt độ ổn định 22 độ C. Để đảm bảo cây 5 cm. Dùng đèn công suất 3 - 6W cho mỗi chậu. Đèn trồng cây ở Việt Nam giá khoảng vài chục đến vài trăm nghìn đồng.

1,123 characters - 265 words

Decode Mode

Autoregressive

MTP Verified

Max Tokens: 256

Multi-Token Prediction with train-head verification

Summarize

Summary

MTP Verified

Chọn vị trí có ánh sáng mạnh. Đặt cây con ở nơi có ánh nắng trực tiếp trên mặt trời. Đảm bảo cây nhận được nhiều ánh nắng mặt trời vào chậu hạt trong phòng ẩm áp và có ánh nắng. Tưới nước cho cây con. Tia cây.

Performance Metrics

|         |        |            |            |       |         |
|---------|--------|------------|------------|-------|---------|
| LATENCY | TOKENS | SPEED      | ACCEPTANCE | STEPS | SPEEDUP |
| 2.21s   | 69     | 31.3 tok/s | 15.7%      | 27    | 2.63x   |

LLM2Seq - Encoder-Decoder with Multi-Token Prediction © Github

## Chế độ verified MTP

# Thảo luận và hạn chế

## Điểm làm được

- Source encoder từ LLM có thể tạo memory cho decoder.
- Token-level memory hữu ích cho tóm tắt bám nguồn.
- Verified MTP tạo ra tăng tốc thực, dù chưa lớn.

## Hạn chế hiện tại

- Chưa có adapter ablation đầy đủ.
- Chưa có đánh giá factuality bằng người.
- MTP còn tốn chi phí kiểm chứng và cache.

Hướng làm khả thi, nhưng chưa khẳng định vượt T5Gemma trên mọi mặt.

- LLM2Seq dùng LLM source encoder để tạo memory cho decoder.
- Qwen cho chất lượng tốt hơn Llama và độ dài gần tham chiếu hơn.
- Verified MTP đạt 1.17x, nhưng bị giới hạn bởi bước kiểm chứng.

### Bước tiếp theo

Adapter ablation, factuality evaluation, và tối ưu verified decoding.



**Cảm ơn đã lắng nghe!**

GitHub:  
[github.com/BienKieu1411/LLM2Seq](https://github.com/BienKieu1411/LLM2Seq)

