

LLM2Seq

Vietnamese Summarization with LLM Source Encoders and Verified MTP

Kiều Giang Biên

Hanoi University of Science and Technology

Báo cáo mini project

WikiLingua và LR-Sum tiếng Việt

Từ bài toán đến hướng tiếp cận

Bài toán

Tóm tắt cần đọc văn bản nguồn rồi viết lại ngắn gọn.

Khoảng trống

Decoder-only LLM viết tốt, nhưng khó dùng trực tiếp như encoder.

Hướng làm

Dùng LLM đọc nguồn.
Adapter chuyển biểu diễn sang decoder.

LLM2Seq giữ thông tin theo từng token, thay vì nén nguồn quá sớm.

Decoder còn thấy chi tiết trong nguồn, đồng thời tận dụng biểu diễn mạnh từ LLM.


Vì sao không chỉ dùng nén ngữ cảnh?

Nén ngữ cảnh


- Nén văn bản dài thành chuỗi ẩn ngắn hơn.
- Hữu ích cho suy luận với ngữ cảnh dài.
- Không được thiết kế riêng cho tóm tắt bám nguồn.

LLM2Seq

- Giữ source memory theo từng token nguồn.
- Decoder đọc nguồn bằng cross-attention.
- Giảm nguy cơ mất tên riêng, số liệu và bước thao tác.



LLM2Seq: tổng quan kiến trúc




LLM đọc nguồn $\rightarrow$ adapter tạo source memory $\rightarrow$ decoder nhẹ $\rightarrow$ verified MTP.

Adapter: nối biểu diễn nguồn với decoder

Ý tưởng

- Lấy hidden states từ LLM đọc nguồn.
- Trộn thông tin từ nhiều layer của LLM.
- Gated projection đưa biểu diễn sang không gian decoder.
- Decoder đọc source memory bằng cross-attention.



Mục tiêu: dùng lại biểu diễn của LLM, nhưng vẫn giữ cấu trúc encoder-decoder. Adapter không tạo encoder mới từ đầu. Nó chuyển hidden states của LLM thành source memory cho decoder.


Self-distilled MTP: tăng tốc có kiểm chứng

Huấn luyện

- Huấn luyện summarizer trước.
- Đóng băng encoder, adapter và decoder.
- Chỉ cập nhật 4 MTP heads.


Suy luận

- MTP dự đoán vài token tiếp theo.
- Decoder kiểm chứng token nháp.
- Chỉ ghi token đã được xác nhận.



chỉ nhận token đã được kiểm chứng

Dữ liệu: WikiLingua và LR-Sum tiếng Việt



WikiLingua

- Huấn luyện: 13,999
- Xác thực: 1,680
- Kiểm thử: 3,901
- Nguồn: WikiHow

LR-Sum

- Huấn luyện: 11,676
- Xác thực: 1,459
- Kiểm thử: 1,460
- Nguồn: VOA newswire

Thiết lập thí nghiệm

Hệ thống so sánh

- LLM2Seq-Llama
- LLM2Seq-Qwen
- T5Gemma LoRA

Thước đo

- ROUGE-1/2/L
- BERTScore mBERT
- Thống kê độ dài
- Token/s và độ trễ


Dữ liệu

- WikiLingua
- LR-Sum

Cần trả lời ba câu hỏi: tóm tắt tốt không, dài ngắn ra sao, và chạy nhanh hơn bao nhiêu.
BERTScore dùng bert-base-multilingual-cased. AR-MTP chỉ so sánh trên WikiLingua.

Kết quả chính: chất lượng tóm tắt

Quality metrics by dataset



WikiLingua: Qwen gần T5Gemma ở ROUGE-1, nhưng thấp hơn ở ROUGE-2 và ROUGE-L.

LR-Sum: Qwen hơn Llama, nhưng T5Gemma vẫn mạnh nhất.

Bảng kết quả chính

Dataset	Model	R-1	R-2	R-L	BERT-P	BERT-R	BERT-F1
WikiLingua	LLM2Seq-Llama	48.36	15.54	29.05	74.08	72.11	73.02
	LLM2Seq-Qwen	54.01	20.83	31.83	72.87	74.11	73.42
	T5Gemma	54.24	27.42	33.89	71.99	78.40	74.98
LR-Sum	LLM2Seq-Llama	50.49	12.08	29.41	70.74	69.26	69.98
	LLM2Seq-Qwen	51.59	15.58	31.21	72.24	71.04	71.62
	T5Gemma	58.79	27.34	39.86	74.13	75.24	74.65

Nhìn chung


Qwen tốt hơn Llama trên cả hai dataset.

So với T5Gemma

T5Gemma vẫn mạnh hơn, nhất là ROUGE-2 và ROUGE-L.


Kết quả độ dài: không chỉ nhìn ROUGE

Generated length vs. reference length



Nhận xét: Llama thường ngắn. Qwen gần độ dài tham chiếu hơn. T5Gemma đầy đủ hơn, nhưng có xu hướng dài.

MTP trên WikiLingua: tăng tốc vừa phải




Quan sát trên Qwen

- AR: 95.87 tok/s
- MTP: 111.71 tok/s
- Tăng tốc: 1.17x
- Sinh ra: 2.30 token/bước
- Draft được nhận: 0.44 token/bước

Kết quả MTP này được đo trên WikiLingua.

Vì sao MTP trên WikiLingua chưa tăng tốc mạnh?



Nếu tính lý tưởng

Nếu chỉ xét việc sinh 2.30 token/bước, độ trễ kỳ vọng là 0.339s. Thực tế đo được là 0.662s.

Phần còn lại

Phần chênh 0.323s cho thấy thời gian còn mất ở kiểm chứng token, quản lý cache, điều phối tensor và overhead Python.

Demo hệ thống

LLM2Seq

Text Summarization

Model: Ready

Embed-Embedding-0.48

Source Text

WikiLingua Test Sample

X Clear

Dùng để chứa nội dung văn bản gốc để xử lý hoặc gán là mẫu, vì những nội dung không khi quá nhỏ và ngắn. Từ tương đương tổng hợp là những vị trí trong nhà thích hợp cho cây này. Đây là nhiệt độ trong khoảng 24 - 29 độ C cho cây phát triển tốt. Dùng bình xịt để giữ ẩm cho hạt. Đảm bảo đất phải ẩm nhưng không ướt sũng hoặc nhỏ giọt. Tránh để đất bị úng nước, vì điều này có thể dẫn đến các vấn đề liên quan đến tình trạng tưới quá nhiều. Tưới cây theo lịch để giữ độ ẩm cho cây. Bạn có thể xịt nước cho cây một lần vào buổi sáng và một lần vào ban đêm để cung cấp đủ nước cho cây. Hạt cây sẽ cần ánh sáng 24 tiếng mỗi ngày, 7 ngày một tuần để phát triển. Bạn cần dùng ánh sáng trắng lạnh có nhiệt độ ổn định 22 độ C. Để đảm bảo cây 5 cm. Dùng đèn công suất 3 - 6W cho mỗi chậu. Đèn trồng cây ở Việt Nam giá khoảng vài chục đến vài trăm.

1,125 characters - 265 words

Decode Mode

Autoregressive

MTP Verified

Max Tokens: 256

Standard token-by-token decoding

Summarize

Summary

Autoregressive

Chọn vị trí có ánh sáng mạnh. Đặt cây con sang khu vực có nắng. Tỉm một chậu trồng cây lớn. Tưới cây khi đất khô hạt giống hoặc cây con vào chậu. Hạt giống sẽ vào chậu hoặc chậu cây con trong phòng ẩm áp và có ánh nắng.

Performance Metrics

LATENCY	TOKENS	SPEED
3.27s	74	22.6 tok/s

LLM2Seq - Encoder-Decoder with Multi-Token Prediction © Github

Chế độ autoregressive

LLM2Seq

Text Summarization

Model: Ready

Embed-Embedding-0.48

Source Text

WikiLingua Test Sample

X Clear

Dùng để chứa nội dung văn bản gốc để xử lý hoặc gán là mẫu, vì những nội dung không khi quá nhỏ và ngắn. Từ tương đương tổng hợp là những vị trí trong nhà thích hợp cho cây này. Đây là nhiệt độ trong khoảng 24 - 29 độ C cho cây phát triển tốt. Dùng bình xịt để giữ ẩm cho hạt. Đảm bảo đất phải ẩm nhưng không ướt sũng hoặc nhỏ giọt. Tránh để đất bị úng nước, vì điều này có thể dẫn đến các vấn đề liên quan đến tình trạng tưới quá nhiều. Tưới cây theo lịch để giữ độ ẩm cho cây. Bạn có thể xịt nước cho cây một lần vào buổi sáng và một lần vào ban đêm để cung cấp đủ nước cho cây. Hạt cây sẽ cần ánh sáng 24 tiếng mỗi ngày, 7 ngày một tuần để phát triển. Bạn cần dùng ánh sáng trắng lạnh có nhiệt độ ổn định 22 độ C. Để đảm bảo cây 5 cm. Dùng đèn công suất 3 - 6W cho mỗi chậu. Đèn trồng cây ở Việt Nam giá khoảng vài chục đến vài trăm.

1,125 characters - 265 words

Decode Mode

Autoregressive

MTP Verified

Max Tokens: 256

Multi-Token Prediction with train-head verification

Summarize

Summary

MTP Verified

Chọn vị trí có ánh sáng mạnh. Đặt cây con ở nơi có ánh nắng trực tiếp trên mặt trời. Đảm bảo cây nhận được nhiều ánh nắng mặt trời vào chậu hạt trong phòng ẩm áp và có ánh nắng. Tưới nước cho cây con. Tia cây.

Performance Metrics

LATENCY	TOKENS	SPEED	ACCEPTANCE	STEPS	SPEEDUP
2.21s	69	31.3 tok/s	15.7%	27	2.63x

LLM2Seq - Encoder-Decoder with Multi-Token Prediction © Github

Chế độ verified MTP

Kết quả rút ra

- Có thể dùng LLM làm phần đọc nguồn cho decoder.
- Qwen tốt hơn Llama trên cả hai dataset.
- Verified MTP giúp chạy nhanh hơn trên WikiLingua.

Hạn chế hiện tại

- Chưa chạy đầy đủ ablation cho từng phần của adapter.
- Chưa có đánh giá thủ công về độ đúng nghĩa.
- MTP vẫn tốn chi phí kiểm chứng và cache.

LLM2Seq-Qwen tốt hơn Llama, nhưng chưa vượt T5Gemma.

- LLM2Seq dùng LLM để đọc nguồn, rồi chuyển source memory cho decoder.
- Qwen tốt hơn Llama trên WikiLingua và LR-Sum tiếng Việt.
- T5Gemma vẫn mạnh hơn, đặc biệt ở ROUGE-2 và ROUGE-L.
- Verified MTP đạt 1.17x trên WikiLingua, nhưng còn tốn chi phí kiểm chứng.

Bước tiếp theo

Chạy thêm ablation cho adapter, đánh giá độ đúng nghĩa, và tối ưu verified decoding.



Cảm ơn đã lắng nghe!

GitHub:
github.com/BienKieu1411/LLM2Seq

