

LLM2Seq: Repurposing LLM Encoders for Encoder-Decoder Summarization with Self-Distilled Multi-Token Prediction

**Vietnamese Summarization with Repurposed LLM Encoders and Verified
MTP**

Kiều Giang Biên

Hanoi University of Science and Technology

Từ bài toán đến hướng tiếp cận

Bài toán

Tóm tắt cần đọc văn bản nguồn rồi viết lại ngắn gọn.

Khoảng trống

Decoder-only LLM sinh văn bản tốt, nhưng không có giao diện encoder-decoder trực tiếp cho tóm tắt.

Hướng làm

Dùng LLM đọc nguồn. Adapter chuyển biểu diễn sang decoder.

LLM2Seq giữ thông tin theo từng token, thay vì nén nguồn quá sớm.

Decoder còn thấy chi tiết trong nguồn, đồng thời tận dụng biểu diễn mạnh từ LLM.

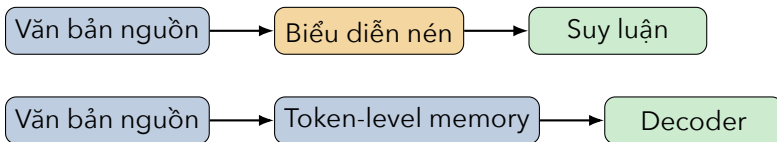
Vì sao không chỉ dùng nén ngữ cảnh?

Nén ngữ cảnh


- Nén văn bản dài thành chuỗi ẩn ngắn hơn.
- Hữu ích cho suy luận với ngữ cảnh dài.
- Không được thiết kế riêng cho tóm tắt bám nguồn.

LLM2Seq

- Giữ source memory theo từng token nguồn.
- Decoder đọc nguồn bằng cross-attention.
- Giảm nguy cơ mất tên riêng, số liệu và bước thao tác.



LLM2Seq: tổng quan kiến trúc




LLM đọc nguồn → adapter tạo source memory → decoder nhẹ → verified MTP.

Adapter: nối biểu diễn nguồn với decoder

Ý tưởng

- Lấy hidden states từ LLM đọc nguồn.
- Trộn thông tin từ nhiều layer của LLM.
- Gated projection đưa biểu diễn sang không gian decoder.
- Decoder đọc source memory bằng cross-attention.

Gated residual memory adapter



Layer mixing + gated update + source-memory refinement


Self-distilled MTP: tăng tốc có kiểm chứng

Huấn luyện

- Huấn luyện summarizer trước.
- Đóng băng encoder, adapter và decoder.
- Chỉ cập nhật 4 MTP heads.


Suy luận

- MTP dự đoán vài token tiếp theo.
- Decoder kiểm chứng token nháp.
- Chỉ ghi token đã được xác nhận.



chỉ append token sau khi decoder chính xác nhận

Dữ liệu: quy mô train/validation/test



Hai bộ dữ liệu có quy mô train lớn hơn rõ rệt so với validation/test, phù hợp cho fine-tuning và đánh giá held-out.

Dữ liệu: hai nguồn tóm tắt tiếng Việt

WikiLingua

- Nguồn: WikiHow-style instructional articles.
- Split: 13,999 train / 1,680 validation / 3,901 test.
- Kiểm tra khả năng tóm tắt văn bản hướng dẫn nhiều bước.

LR-Sum

- Nguồn: VOA newswire.
- Split: 11,676 train / 1,459 validation / 1,460 test.
- Kiểm tra khả năng tóm tắt tin tức ngắn gọn hơn.

Dùng cả hai dataset giúp kiểm tra LLM2Seq trên hai kiểu văn bản khác nhau.

Thiết lập thí nghiệm

Hệ thống so sánh

- LLM2Seq-Llama
- LLM2Seq-Qwen
- T5Gemma LoRA

Thuốc đo

- ROUGE-1/2/L
- BERTScore mBERT
- Thống kê độ dài
- Token/s và độ trễ

Dữ liệu


- WikiLingua
- LR-Sum

Ba câu hỏi: chất lượng, độ dài, và tốc độ.

Kết quả chính: chất lượng tóm tắt


Chất lượng tóm tắt theo dataset và metric

WikiLingua



WikiLingua: Qwen gần T5Gemma ở ROUGE-1, nhưng thấp hơn ở ROUGE-2 và ROUGE-L.

Llama Qwen T5Gemma
LR-Sum



LR-Sum: Trong cấu hình LLM2Seq, Qwen hơn Llama, nhưng T5Gemma vẫn mạnh nhất.

Bảng kết quả chính

Dataset	Model	R-1	R-2	R-L	BERT-F1
	LLM2Seq-Llama	48.36	15.54	29.05	73.02
	LLM2Seq-Qwen	54.01	20.83	31.83	73.42
	T5Gemma	54.24	27.42	33.89	74.98
	LLM2Seq-Llama	50.49	12.08	29.41	69.98
	LLM2Seq-Qwen	51.59	15.58	31.21	71.62
	T5Gemma	58.79	27.34	39.86	74.65



Nhìn chung

Trong cấu hình LLM2Seq, Qwen tốt hơn Llama trên cả hai dataset.

So với T5Gemma

T5Gemma vẫn mạnh hơn, nhất là ROUGE-2 và ROUGE-L.



Kết quả độ dài: không chỉ nhìn ROUGE



Nhận xét: Llama thường ngắn. Qwen gần độ dài tham chiếu hơn. T5Gemma dài hơn, giúp tăng overlap nhưng kém cô đọng hơn.

MTP trên WikiLingua: tăng tốc vừa phải

Verified MTP tăng throughput nhưng không tỷ lệ với token/bước



Quan sát trên Qwen

Throughput

95.87 111.71 tok/s

Speedup

1.17x


Emitted

2.30 token/step

Accepted draft

0.44 token/step

Vì sao MTP trên WikiLingua chưa tăng tốc mạnh?



Nếu tính lý tưởng

2.30 token/bước cho latency lý tưởng 0.339s; thực tế là 0.662s.

Phần còn lại

Chênh 0.323s đến từ verification, cache, tensor control và Python overhead.

Demo hệ thống

LLM2Seq

Text Summarization

Model: Ready

Queue: tokenizing - 0.48

Source Text

WikiLingua Text Sample

X Clear

Bình dặt chậu gieo hạt trên bề mặt của sỏi hoặc gần lò sưởi, vì những nơi này không khi quá khô và nóng. Tủ tường hoặc tầng hầm là những vị trí trong nhà thích hợp cho cây này miễn. Duy trì nhiệt độ trong khoảng 24 - 29 độ C cho cây phát triển tốt. Dùng bình xịt để giữ ẩm cho hạt. Đảm bảo đất phải ẩm nhưng không ướt sũng hoặc nhỏ giọt. Tránh để đất bị úng nước, vì điều này có thể dẫn đến các vấn đề liên quan đến tình trạng tưới quá nhiều. Tưới cây theo lịch để giữ độ ẩm cho cây. Bạn có thể xịt nước cho cây một lần vào buổi sáng và một lần vào ban đêm để cung cấp đủ nước cho cây. Hạt cây gai dầu cần ánh sáng 24 tiếng mỗi ngày, 7 ngày một tuần để phát triển. Bạn cần dùng ánh sáng trắng lạnh có nhiệt độ ổn định 22 độ C. Để đến cách chậu cây 5 cm. Dùng đèn công suất 3 - 5W cho mỗi chậu. Đèn trồng cây ở Việt Nam giá khoảng vài chục đến vài trăm nghìn đồng. Bạn không biết có thể mua đèn trồng cây cho từng loại cây trồng tại nhà không? Để tìm hiểu.

1125 characters - 203 words

Decode Mode

Autoregressive

MTP Verified

Max Tokens: 256

Standard token-by-token decoding

Summarize

Summary

Autoregressive

Chọn vị trí có ánh sáng mạnh. Đặt cây con sang khu vực có nắng. Tìm một chậu trồng cây lớn. Tưới cây khi đất khô hết giống hoặc cây con vào chậu. Hạt giống sẽ vào chậu hoặc chậu cây con vào chậu trong phòng ẩm áp và có nắng nóng.

Performance Metrics

LATENCY

2.21s

TOKENS

74

SPEED

22.4 tok/s

LLM2Seq - Encoder-Decoder with Multi-Token Prediction. GitHub

Autoregressive

LLM2Seq

Text Summarization

Model: Ready

Queue: tokenizing - 0.48

Source Text

WikiLingua Text Sample

X Clear

Bình dặt chậu gieo hạt trên bề mặt của sỏi hoặc gần lò sưởi, vì những nơi này không khi quá khô và nóng. Tủ tường hoặc tầng hầm là những vị trí trong nhà thích hợp cho cây này miễn. Duy trì nhiệt độ trong khoảng 24 - 29 độ C cho cây phát triển tốt. Dùng bình xịt để giữ ẩm cho hạt. Đảm bảo đất phải ẩm nhưng không ướt sũng hoặc nhỏ giọt. Tránh để đất bị úng nước, vì điều này có thể dẫn đến các vấn đề liên quan đến tình trạng tưới quá nhiều. Tưới cây theo lịch để giữ độ ẩm cho cây. Bạn có thể xịt nước cho cây một lần vào buổi sáng và một lần vào ban đêm để cung cấp đủ nước cho cây. Hạt cây gai dầu cần ánh sáng 24 tiếng mỗi ngày, 7 ngày một tuần để phát triển. Bạn cần dùng ánh sáng trắng lạnh có nhiệt độ ổn định 22 độ C. Để đến cách chậu cây 5 cm. Dùng đèn công suất 3 - 5W cho mỗi chậu. Đèn trồng cây ở Việt Nam giá khoảng vài chục đến vài trăm nghìn đồng. Bạn không biết có thể mua đèn trồng cây cho từng loại cây trồng tại nhà không? Để tìm hiểu.

1125 characters - 203 words

Decode Mode

Autoregressive

MTP Verified

Max Tokens: 256

Multi-Token Prediction with main-head verification

Summarize

Summary

MTP Verified

Chọn vị trí có ánh sáng mạnh. Đặt cây con ở nơi có nắng nóng trực tiếp trên mặt trời. Đảm bảo cây nhận được nhiều ánh nắng mặt trời vào chậu hạt trong phòng ẩm áp và có ánh nắng. Tưới nước cho cây con. Tia cây.

Performance Metrics

LATENCY

2.21s

TOKENS

49

SPEED

31.3 tok/s

ACCEPTANCE

15.7%

STEPS

27

SPEEDUP

2.65x

LLM2Seq - Encoder-Decoder with Multi-Token Prediction. GitHub

Verified MTP

Thảo luận và hạn chế

Kết quả rút ra

- Có thể dùng LLM làm phần đọc nguồn cho decoder.
- Trong cấu hình LLM2Seq, Qwen tốt hơn Llama trên cả hai dataset.
- Verified MTP giúp chạy nhanh hơn trên WikiLingua.

Hạn chế hiện tại

- Chưa chạy đầy đủ ablation cho từng phần của adapter.
- Chưa có đánh giá thủ công về factuality / độ đúng nội dung.
- MTP vẫn tốn chi phí kiểm chứng và cache.

Trong cấu hình LLM2Seq, Qwen tốt hơn Llama, nhưng chưa vượt T5Gemma.

Thông điệp chính

- LLM2Seq chuyển hidden states từ LLM encoder thành source memory cho decoder.
- Trong cấu hình LLM2Seq, Qwen tốt hơn Llama trên WikiLingua và LR-Sum tiếng Việt.
- T5Gemma vẫn mạnh hơn, đặc biệt ở ROUGE-2 và ROUGE-L.
- Verified MTP đạt 1.17x trên WikiLingua, nhưng còn tốn chi phí kiểm chứng.

Bước tiếp theo

Chạy thêm ablation cho adapter, đánh giá factuality / độ đúng nội dung, và tối ưu verified decoding.

Thank you
Q&A

GitHub:
github.com/BienKieu1411/LLM2Seq

