

LLM2Seq: Repurposing LLM Encoders for Encoder-Decoder Summarization with Self-Distilled Multi-Token Prediction

Kiều Giang Biên

Hanoi University of Science and Technology

Từ bài toán đến hướng tiếp cận

Bài toán

Mô hình cần đọc văn bản nguồn rồi viết lại thành bản tóm tắt ngắn gọn.

Khoảng trống

Decoder-only LLM sinh văn bản tốt, nhưng không có giao diện encoder-decoder trực tiếp cho tóm tắt.

Hướng làm

Dùng LLM làm bộ đọc nguồn. Adapter chuyển biểu diễn sang decoder.

LLM2Seq giữ thông tin theo từng token, thay vì nén nguồn quá sớm.

Decoder vẫn nhìn thấy chi tiết trong nguồn, đồng thời tận dụng biểu diễn mạnh từ LLM.

Vì sao không chỉ dùng nén ngữ cảnh?

Nén ngữ cảnh

- Nén văn bản dài thành chuỗi ẩn ngắn hơn.
- Hữu ích cho suy luận với ngữ cảnh dài.
- Không được thiết kế riêng cho tóm tắt bám nguồn.


LLM2Seq

- Giữ bộ nhớ nguồn theo từng token.
- Decoder đọc nguồn bằng cross-attention.
- Giảm nguy cơ mất tên riêng, số liệu và bước thao tác.

Nén ngữ cảnh



LLM2Seq



Phát biểu bài toán

Mục tiêu

Tìm mô hình ước lượng phân phối của bản tóm tắt $y = (y_1, \dots, y_n)$ dựa trên văn bản nguồn $x = (x_1, \dots, x_m)$:


$$p(y|x) = \prod_{t=1}^n p(y_t | y_{<t}, x)$$

Công thức hóa LLM2Seq

- **Encoder:** Trích xuất hidden states từ LLM, $H = E_{\theta}(x)$.
- **Adapter:** Biến đổi thành không gian bộ nhớ của decoder, $M = A_{\phi}(H)$.
- **Decoder:** Sinh từng token tóm tắt dựa trên token trước đó và bộ nhớ nguồn, $p(y|x) = \prod_{t=1}^n p_{\psi}(y_t | y_{<t}, M)$.

Việc tách biệt này giúp Encoder tập trung hiểu nguồn, Decoder tập trung sinh văn bản.

LLM2Seq: tổng quan kiến trúc




Encoder dùng LLM2Vec-Sheared-LLaMA hoặc Qwen3-Embedding-0.6B; decoder nhẹ; MTP có kiểm chứng.

Adapter: nối biểu diễn nguồn với decoder

Các module cốt lõi

1. **Token-wise Layer Fusion:** Trộn thông tin từ nhiều layer LLM theo từng token.
2. **Gated Residual Projection:** Đưa biểu diễn sang không gian của decoder.
3. **Token Saliency Gate:** Đánh giá và nhấn mạnh các token mang thông tin quan trọng.
4. **EncStack:** Dùng 4 layer Transformer để tinh chỉnh cục bộ bộ nhớ nguồn.
5. **Global Memory Tokens:** Cung cấp các token toàn cục cho decoder tham chiếu.

Gated residual memory adapter



Layer mixing + gated update + memory refinement

Huấn luyện theo từng mức can thiệp

Mỗi giai đoạn chỉ mở thêm phần cần thiết: học đọc nguồn, thích ứng encoder, rồi tăng tốc suy luận.

GĐ 1: Khởi tạo

Cố định

LLM encoder

Cập nhật

Adapter và decoder

Kết quả

Decoder học đọc bộ nhớ nguồn M .



GĐ 2: Thích ứng

Mở khóa

LoRA trên LLM encoder

Cập nhật

LoRA, adapter và decoder

Kết quả

Nguồn khớp hơn với tác vụ tóm tắt.



GĐ 3: Tăng tốc

Cố định

Mô hình sau GĐ 2

Cập nhật

4 MTP heads

Kết quả

Draft-and-verify giảm số bước tự hồi quy.

Self-distilled MTP: tăng tốc có kiểm chứng

Huấn luyện

- Huấn luyện mô hình tóm tắt trước.
- Đóng băng encoder, adapter và decoder.
- Chỉ cập nhật 4 MTP heads.


Suy luận

- MTP dự đoán vài token tiếp theo.
- Decoder kiểm chứng token nhập.
- Chỉ ghi token đã được xác nhận.



Chỉ thêm token sau khi decoder chính xác nhận

Dữ liệu: quy mô train/validation/test



Train dùng để fine-tuning; validation hỗ trợ chọn cấu hình, còn test dùng cho kết quả cuối.

Dữ liệu: hai nguồn tóm tắt tiếng Việt

WikiLingua

instructional articles

Nguồn văn bản

Bài viết hướng dẫn kiểu WikiHow, thường gồm nhiều bước thao tác.

Điều kiểm tra

Dài hơn

Kiểm tra khả năng giữ trình tự và chi tiết trong nguồn.

Bám nguồn

Dễ lộ lỗi khi mô hình bỏ sót bước hoặc số liệu.

LR-Sum

news articles

Nguồn văn bản

Tin tức VOA tiếng Việt, ngắn hơn và tập trung vào thông tin sự kiện.

Điều kiểm tra

Cô đọng

Kiểm tra khả năng chọn ý chính thay vì kể lại quá dài.

Tin tức

Phù hợp để đánh giá tóm tắt đúng trọng tâm.

Hai nguồn dữ liệu tạo áp lực khác nhau: một bên cần giữ trình tự, một bên cần cô đọng ý chính.

Thiết lập thí nghiệm

Ba hệ thống so sánh

LLM2Seq-Llama	LLM2Vec-Sheared-LLaMA encoder
LLM2Seq-Qwen	Qwen3-Embedding-0.6B encoder
T5Gemma	T5Gemma-2-1B-1B LoRA baseline

Dữ liệu kiểm thử

- WikiLingua: tóm tắt hướng dẫn, cần giữ trình tự thao tác.
- LR-Sum: văn bản dài, cần cô đọng ý chính.


Bốn góc nhìn đánh giá

- **N-gram**: ROUGE-1/2/L
- **Ngữ nghĩa**: BERTScore mBERT
- **Hành vi sinh**: thống kê độ dài
- **Tốc độ**: token/s và độ trễ

Chất lượng, độ dài và tốc độ được đọc cùng nhau.


Kết quả chính: chất lượng tóm tắt

Chất lượng tóm tắt theo dataset và metric
WikiLingua



WikiLingua: Qwen gần T5Gemma ở ROUGE-1, nhưng thấp hơn ở ROUGE-2 và ROUGE-L.

Llama Qwen T5Gemma
LR-Sum



LR-Sum: Trong cấu hình LLM2Seq, Qwen hơn Llama, nhưng T5Gemma vẫn đạt điểm cao nhất.

Bảng kết quả chính

Dataset	Model	R-1	R-2	R-L	BERT-F1
WikiLingua	LLM2Seq-Llama	48.36	15.54	29.05	73.02
	LLM2Seq-Qwen	54.01	20.83	31.83	73.42
	T5Gemma	54.24	27.42	33.89	74.98
LR-Sum	LLM2Seq-Llama	50.49	12.08	29.41	69.98
	LLM2Seq-Qwen	51.59	15.58	31.21	71.62
	T5Gemma	58.79	27.34	39.86	74.65



Nhìn chung

Trong cấu hình LLM2Seq, Qwen tốt hơn Llama trên cả hai bộ dữ liệu.

So với T5Gemma

T5Gemma vẫn mạnh hơn, nhất là ROUGE-2 và ROUGE-L.

Kết quả độ dài: không chỉ nhìn ROUGE



Nhận xét: Llama thường sinh ngắn. Qwen gần độ dài tham chiếu hơn. T5Gemma dài hơn, tăng độ trùng nhưng kém cô đọng hơn.

Ví dụ định tính: Qwen giữ ý nguồn tốt hơn

Văn bản nguồn (WikiLingua)

... Tùy vào loại da và mức độ nghiêm trọng của mụn ẩn mà bạn nên cân nhắc giữa phương pháp chườm ấm với chườm lạnh. Chườm ấm giúp làm khô mụn ẩn; chườm lạnh giúp giảm sưng đau. Không nên chườm đá trong giai đoạn đầu. Nếu là mụn lớn, viêm nghiêm trọng, nên chườm ấm để rút dịch ...

LLM2Seq-Llama

Sinh ra

Dùng gel lô hội.
Thoa sữa rửa mặt nhẹ dịu.
Dùng bằng dầu tràm trà.
Dưỡng ẩm cho da.

Hành vi

Quá ngắn, bỏ mất ý chính và tự thêm chi tiết ngoài nguồn.

LLM2Seq-Qwen

Sinh ra

Chườm đá viên lên mụn.
Chườm gạc ẩm lên mụn để giảm đau.
Sử dụng tinh dầu tràm trà...

Hành vi

Bắt được ý chính về chườm ấm/lạnh, nhưng còn lẫn chỉ dẫn.

T5Gemma

Sinh ra


Chườm ấm hoặc chườm lạnh.
Thử dùng táo và mật ong...
Dùng tinh dầu tràm trà...

Hành vi

Diễn đạt tự nhiên hơn, nhưng sinh thêm thông tin phụ.

MTP trên WikiLingua: tăng tốc vừa phải

Verified MTP tăng throughput nhưng không tỷ lệ với token/bước



Quan sát trên Qwen

verified MTP


Throughput
95.87 -> 111.71 tok/s

Speedup
1.17x

Emitted
2.30 token/step

Accepted draft
0.44 token/step

Vì sao MTP trên WikiLingua chưa tăng tốc mạnh?



Nếu tính lý tưởng

2.30 token/bước tương ứng 0.339s lý tưởng; đo thực tế 0.662s.

Phần còn lại

Chênh 0.323s chủ yếu đến từ bước kiểm chứng, cache và chi phí Python.

Demo hệ thống

LLM2Seq

Text Summarization

Model: Ready

Queue: Embedding - 0.48

Source Text

WikiLingua Text Sample

X Clear

Bình dặt chậu geo hạt trên bề của số hoặc gần lò sưởi, vì những nơi này không khí quá khô và nóng. Tủ tường hoặc tầng hầm là những vị trí trong nhà thích hợp cho cây này miễn. Duy trì nhiệt độ trong khoảng 24 - 29 độ C cho cây phát triển tốt. Dùng bình xịt để giữ ẩm cho hạt. Đảm bảo đất phải ẩm nhưng không ướt sũng hoặc nhỏ giọt. Tránh để đất bị úng nước, vì điều này có thể dẫn đến các vấn đề liên quan đến tình trạng tưới quá nhiều. Tưới cây theo lịch để giữ độ ẩm cho cây. Bạn có thể xịt nước cho cây một lần vào buổi sáng và một lần vào ban đêm để cung cấp đủ nước cho cây. Hạt cây gai dầu cần ánh sáng 24 tiếng mỗi ngày, 7 ngày một tuần để phát triển. Bạn cần dùng ánh sáng trắng lạnh có nhiệt độ ổn định 22 độ C. Để đến cách chậu cây 5 cm. Dùng đèn công suất 3 - 5W cho mỗi chậu. Đèn trồng cây ở Việt Nam giá khoảng vài chục đến vài trăm nghìn đồng. Bạn không biết có thể mua đèn trồng cây ở đâu? Bạn có thể mua đèn trồng cây ở các siêu thị hoặc cửa hàng thực phẩm.

1125 characters - 203 words

Decode Mode

Autoregressive

MTP Verified

Max Tokens: 256

Standard token-by-token decoding

Summarize

Summary

Autoregressive

Chọn vị trí có ánh sáng mạnh. Đặt cây con sang khu vực có nắng. Tìm một chậu trồng cây lớn. Tưới cây khi đất khô hạn giống như cây con vào chậu. Hạt giống sẽ vào chậu hoặc chậu cây con cây con trong phòng ẩm áp và có nắng nóng.

Performance Metrics

LATENCY

2.21s

TOKENS

74

SPEED

22.4 tok/s

LLM2Seq - Encoder-Decoder with Multi-Token Prediction. GitHub

Autoregressive

LLM2Seq

Text Summarization

Model: Ready

Queue: Embedding - 0.48

Source Text

WikiLingua Text Sample

X Clear

Bình dặt chậu geo hạt trên bề của số hoặc gần lò sưởi, vì những nơi này không khí quá khô và nóng. Tủ tường hoặc tầng hầm là những vị trí trong nhà thích hợp cho cây này miễn. Duy trì nhiệt độ trong khoảng 24 - 29 độ C cho cây phát triển tốt. Dùng bình xịt để giữ ẩm cho hạt. Đảm bảo đất phải ẩm nhưng không ướt sũng hoặc nhỏ giọt. Tránh để đất bị úng nước, vì điều này có thể dẫn đến các vấn đề liên quan đến tình trạng tưới quá nhiều. Tưới cây theo lịch để giữ độ ẩm cho cây. Bạn có thể xịt nước cho cây một lần vào buổi sáng và một lần vào ban đêm để cung cấp đủ nước cho cây. Hạt cây gai dầu cần ánh sáng 24 tiếng mỗi ngày, 7 ngày một tuần để phát triển. Bạn cần dùng ánh sáng trắng lạnh có nhiệt độ ổn định 22 độ C. Để đến cách chậu cây 5 cm. Dùng đèn công suất 3 - 5W cho mỗi chậu. Đèn trồng cây ở Việt Nam giá khoảng vài chục đến vài trăm nghìn đồng. Bạn không biết có thể mua đèn trồng cây ở đâu? Bạn có thể mua đèn trồng cây ở các siêu thị hoặc cửa hàng thực phẩm.

1125 characters - 203 words

Decode Mode

Autoregressive

MTP Verified

Max Tokens: 256

Multi-Token Prediction with main-head verification

Summarize

Summary

MTP Verified

Chọn vị trí có ánh sáng mạnh. Đặt cây con ở nơi có nắng nóng trực tiếp trên mặt trời. Đảm bảo cây nhận được nhiều ánh sáng mặt trời vào chậu hạt trong phòng ẩm áp và có ánh nắng. Tưới nước cho cây con. Tia cây.

Performance Metrics

LATENCY

2.21s

TOKENS

49

SPEED

31.3 tok/s

ACCEPTANCE

15.7%

STEPS

27

SPEEDUP

2.65x

LLM2Seq - Encoder-Decoder with Multi-Token Prediction. GitHub

Verified MTP

Thảo luận và hạn chế

Kết quả rút ra

- Có thể dùng LLM làm bộ đọc nguồn cho decoder.
- Trong cấu hình LLM2Seq, Qwen tốt hơn Llama trên cả hai bộ dữ liệu.
- Verified MTP giúp chạy nhanh hơn trên WikiLingua.

Hạn chế hiện tại

- Chưa chạy đầy đủ ablation cho từng phần của adapter.
- Chưa có đánh giá thủ công về factuality / độ đúng nội dung.
- MTP vẫn tốn chi phí kiểm chứng và cache.

Trong cấu hình LLM2Seq, Qwen tốt hơn Llama, nhưng chưa vượt T5Gemma.

Thông điệp chính

- LLM2Seq chuyển hidden states từ LLM encoder thành source memory cho decoder.
- Trong cấu hình LLM2Seq, Qwen tốt hơn Llama trên WikiLingua và LR-Sum.
- T5Gemma vẫn mạnh hơn, đặc biệt ở ROUGE-2 và ROUGE-L.
- Verified MTP đạt 1.17x trên WikiLingua, nhưng còn tốn chi phí kiểm chứng.

Bước tiếp theo

Chạy thêm ablation cho adapter, đánh giá factuality / độ đúng nội dung, và tối ưu verified decoding.

Thank you
Q&A

GitHub:
github.com/BienKieu1411/LLM2Seq

