

LLM2Seq

Repurposing LLM Source Encoders for Encoder-Decoder Summarization with Self-Distilled MTP

Kiều Giang Biên

Hanoi University of Science and Technology

Báo cáo mini project

Tóm tắt tiếng Việt với source memory và verified MTP

Từ bài toán đến hướng tiếp cận

Bài toán

Tóm tắt cần đọc văn bản nguồn rồi viết lại ngắn gọn.

Khoảng trống

Decoder-only LLM viết tốt, nhưng khó dùng trực tiếp như encoder.

Hướng làm

Dùng LLM đọc nguồn.
Adapter chuyển biểu diễn sang decoder.

LLM2Seq giữ thông tin theo từng token, thay vì nén nguồn quá sớm.

Decoder còn thấy chi tiết trong nguồn, đồng thời tận dụng biểu diễn mạnh từ LLM.


Vì sao không chỉ dùng nén ngữ cảnh?

Nén ngữ cảnh


- Nén văn bản dài thành chuỗi ẩn ngắn hơn.
- Hữu ích cho suy luận với ngữ cảnh dài.
- Không được thiết kế riêng cho tóm tắt bám nguồn.

LLM2Seq

- Giữ source memory theo từng token nguồn.
- Decoder đọc nguồn bằng cross-attention.
- Giảm nguy cơ mất tên riêng, số liệu và bước thao tác.



LLM2Seq: tổng quan kiến trúc




LLM đọc nguồn → adapter tạo source memory → decoder nhẹ → verified MTP.

Adapter: nối biểu diễn nguồn với decoder

Ý tưởng

- Lấy hidden states từ LLM đọc nguồn.
- Trộn thông tin từ nhiều layer của LLM.
- Gated projection đưa biểu diễn sang không gian decoder.
- Decoder đọc source memory bằng cross-attention.



Mục tiêu: dùng lại biểu diễn của LLM, nhưng vẫn giữ cấu trúc encoder-decoder. Adapter không tạo encoder mới từ đầu. Nó chuyển hidden states của LLM thành source memory cho decoder.


Self-distilled MTP: tăng tốc có kiểm chứng

Huấn luyện

- Huấn luyện mô hình tóm tắt chính trước.
- Giữ nguyên encoder, adapter và decoder.
- Chỉ huấn luyện 4 MTP heads bằng CE + KL.

Suy luận


- MTP heads dự đoán trước vài token tiếp theo.
- Decoder chính kiểm chứng từng token nháp.
- Chỉ ghi ra token đã được kiểm chứng.



chỉ nhận token đã được kiểm chứng

Dữ liệu: Vietnamese WikiLingua

Phân chia dữ liệu WikiLingua tiếng Việt



Sau tiền xử lý

- Huấn luyện: 13,999
- Xác thực: 1,680
- Kiểm thử: 3,901
- Tổng sử dụng: 19,580

Một mẫu kiểm thử rỗng đã được loại bỏ.

Thiết lập thí nghiệm

Hệ thống so sánh

- LLM2Seq-Llama
- LLM2Seq-Qwen
- T5Gemma để đối chiếu

Thước đo

- ROUGE-1/2/L
- BERTScore
- Thống kê độ dài
- Token/s và độ trễ


Huấn luyện

- 3 giai đoạn
- LoRA để thích nghi encoder
- MTP heads được huấn luyện sau cùng

Cần trả lời ba câu hỏi: tóm tắt tốt không, dài ngắn ra sao, và chạy nhanh hơn bao nhiêu.

Llama-Qwen được so sánh khi cùng batch. AR-MTP được so sánh trong cùng model và cùng batch.


Kết quả chính: chất lượng tóm tắt



LLM2Seq-Qwen: đạt R-1 54.01 và BERT-F1 73.42.


T5Gemma: cao hơn ở R-2, R-L và BERT-F1, nhưng sinh dài hơn đáng kể.

Kết quả độ dài: không chỉ nhìn ROUGE



Cách đọc: Llama sinh quá ngắn. Qwen gần độ dài tham chiếu hơn. T5Gemma đầy đủ hơn, nhưng thường dài.

MTP: nhiều token mỗi bước, tăng tốc vừa phải




Quan sát trên Qwen

- AR: 95.87 tok/s
- MTP: 111.71 tok/s
- Tăng tốc: 1.17x
- Sinh ra: 2.30 token/bước
- Draft được nhận: 0.44 token/bước

Số token được sinh mỗi bước không đồng nghĩa trực tiếp với thời gian chạy thực tế.

Vì sao MTP chưa tăng tốc mạnh?



Cách đọc

Nếu chỉ xét việc sinh 2.30 token/bước, độ trễ kỳ vọng là 0.339s. Thực tế đo được là 0.662s.

Ý nghĩa

Phần chênh 0.323s cho thấy thời gian còn mất ở kiểm chứng token, quản lý cache, điều phối tensor và overhead Python.

Demo hệ thống

LLM2Seq

Text Summarization

Model: Ready

Embed-Embedding-0.48

Source Text

WikiLingua Text Sample

X Clear

Dùng để chứa nội dung văn bản gốc để xử lý hoặc gán là mẫu, vì những nội dung không khi quá nhỏ và ngắn. Từ tương hoặc tổng hợp là những vị trí trong nhà thích hợp cho cây này. Đây là một độ trong khoảng 24 - 28 độ C cho cây phát triển tốt. Dùng bình xịt để giữ ẩm cho hạt. Đảm bảo đất phải ẩm nhưng không ướt sũng hoặc khô quá. Tránh để đất bị úng nước, vì điều này có thể dẫn đến các vấn đề liên quan đến tình trạng tưới quá nhiều. Tưới cây theo lịch để giữ độ ẩm cho cây. Bạn có thể xịt nước cho cây một lần vào buổi sáng và một lần vào ban đêm để cung cấp đủ nước cho cây. Hạt cây sẽ cần ánh sáng 24 tiếng mỗi ngày, 7 ngày một tuần để phát triển. Bạn cần dùng ánh sáng trắng lạnh có nhiệt độ ổn định 22 độ C. Để đảm bảo cách cây 5 cm. Dùng đèn công suất 3 - 6W cho mỗi chậu. Đèn trồng cây ở Việt Nam giá khoảng vài chục đến vài trăm nghìn đồng.

1,125 characters - 265 words

Decode Mode

Autoregressive

MTP Verified

Max Tokens: 256

Standard token-by-token decoding

Summarize

Summary

Autoregressive

Chọn vị trí có ánh sáng mạnh. Đặt cây con sang khu vực có nắng. Tỉm một chậu trồng cây lớn. Tưới cây khi đất khô hạt giống hoặc cây con vào chậu. Hạt giống sẽ vào chậu hoặc chậu cây con trong phòng ẩm áp và có ánh nắng.

Performance Metrics

LATENCY	TOKENS	SPEED
3.27s	74	22.6 tok/s

LLM2Seq - Encoder-Decoder with Multi-Token Prediction © Github

Chế độ autoregressive

LLM2Seq

Text Summarization

Model: Ready

Embed-Embedding-0.48

Source Text

WikiLingua Text Sample

X Clear

Dùng để chứa nội dung văn bản gốc để xử lý hoặc gán là mẫu, vì những nội dung không khi quá nhỏ và ngắn. Từ tương hoặc tổng hợp là những vị trí trong nhà thích hợp cho cây này. Đây là một độ trong khoảng 24 - 28 độ C cho cây phát triển tốt. Dùng bình xịt để giữ ẩm cho hạt. Đảm bảo đất phải ẩm nhưng không ướt sũng hoặc khô quá. Tránh để đất bị úng nước, vì điều này có thể dẫn đến các vấn đề liên quan đến tình trạng tưới quá nhiều. Tưới cây theo lịch để giữ độ ẩm cho cây. Bạn có thể xịt nước cho cây một lần vào buổi sáng và một lần vào ban đêm để cung cấp đủ nước cho cây. Hạt cây sẽ cần ánh sáng 24 tiếng mỗi ngày, 7 ngày một tuần để phát triển. Bạn cần dùng ánh sáng trắng lạnh có nhiệt độ ổn định 22 độ C. Để đảm bảo cách cây 5 cm. Dùng đèn công suất 3 - 6W cho mỗi chậu. Đèn trồng cây ở Việt Nam giá khoảng vài chục đến vài trăm nghìn đồng.

1,125 characters - 265 words

Decode Mode

Autoregressive

MTP Verified

Max Tokens: 256

Multi-Token Prediction with train-head verification

Summarize

Summary

MTP Verified

Chọn vị trí có ánh sáng mạnh. Đặt cây con ở nơi có ánh nắng trực tiếp trên mặt trời. Đảm bảo cây nhận được nhiều ánh nắng mặt trời vào chậu hạt trong phòng ẩm áp và có ánh nắng. Tưới nước cho cây con. Tia cây.

Performance Metrics

LATENCY	TOKENS	SPEED	ACCEPTANCE	STEPS	SPEEDUP
2.21s	69	31.3 tok/s	15.7%	27	2.63x

LLM2Seq - Encoder-Decoder with Multi-Token Prediction © Github

Chế độ verified MTP

Thảo luận và hạn chế

Điểm làm được

- Có thể dùng LLM làm phần đọc nguồn cho decoder.
- Giữ source memory theo token giúp decoder bám sát văn bản hơn.
- Verified MTP giúp chạy nhanh hơn, nhưng mức tăng chưa lớn.

Hạn chế hiện tại

- Chưa chạy đầy đủ ablation cho từng phần của adapter.
- Chưa có đánh giá thủ công về độ đúng nghĩa.
- MTP vẫn tốn thời gian cho bước kiểm chứng và cache.

Hướng làm này khả thi, nhưng chưa thể nói là hơn T5Gemma ở mọi mặt.

- LLM2Seq dùng LLM để đọc nguồn, rồi chuyển thông tin đó cho decoder.
- Bản Qwen tóm tắt tốt hơn bản Llama và có độ dài gần tham chiếu hơn.
- Verified MTP đạt 1.17x, nhưng vẫn bị giới hạn bởi bước kiểm chứng.

Bước tiếp theo

Chạy thêm ablation cho adapter, đánh giá độ đúng nghĩa, và tối ưu verified decoding.



Cảm ơn đã lắng nghe!

GitHub:
github.com/BienKieu1411/LLM2Seq

